El dataset que falta

Qué variables añadir para potenciar el piloto del Chocó y convertirlo en un visor nacional de hechos de violencia por grupo armado; dónde está cada una; y a quién hay que pedirle lo que no es público.

Alexander Beltrán · Maestría en Ciencia de Datos, Universidad Ean
Bogotá, 29 de octubre de 2026

Cómo leer este documento

Cada variable va marcada con su estado. Ocre: ya la tenemos. Índigo: es pública y solo falta descargarla. Granate: no es pública y hay que pedirla. Al final está la estrategia de solicitudes, con a quién, qué campos exactos pedir y los plazos de ley.

§ 1

Dónde estamos hoy

Inventario honesto de lo que hay en el repositorio, con su cobertura real.

Lo que tenemos	Cobertura	Límite
Panel de reclutamiento del Chocó	31 municipios, 1983–2016, 361 hechos	solo era FARC: deja fuera el 58 % del fenómeno
verdata · reclutamiento nacional	19.226 víctimas, 808 municipios, 1990–2017	100 réplicas, 34 fuentes; termina en 2017
Coca	municipal y anual, 1999–2024, UNODC	la única variable de contexto que ya es anual
Población y áreas	municipal, DANE	–
Geometrías y ríos	31 municipios, tres cauces	la ribereñidad es cálculo nuestro
Alertas de la Defensoría	conteo acumulado por municipio	sin fecha: mide concordancia, no anticipación
Actividad humanitaria	conteo 2016–2025, OCHA	sin desagregar por año

Dos huecos definen todo lo que sigue. El primero es de actores: el panel del piloto solo cuenta hechos de las FARC, y en el Chocó el ELN pesa casi lo mismo. El segundo es de tiempo: ninguna fuente nuestra llega a 2026, de modo que hoy podemos explicar el pasado y no vigilar el presente.

§ 2

La forma del dataset nacional

Una sola tabla, y todo lo demás cuelga de ella.

La unidad debe ser municipio × año × hecho victimizante × presunto responsable. Con 1.122 municipios, 35 años y una decena de hechos, eso son del orden de cuatrocientas mil filas: grande para mirarla, trivial para una máquina.

Esa forma resuelve de una vez tres cosas que hoy están sueltas. Permite preguntar por un hecho concreto o por todos juntos. Permite separar lo que hace cada grupo armado, que es lo que su visor necesita. Y convierte el modelo del Chocó en un caso particular del nacional, en vez de en un trabajo aparte.

Encima de esa tabla van las variables de contexto, que son municipio × año y se unen por código DIVIPOLA. Los siete bloques que siguen son esas variables.

Una advertencia de diseño, aprendida en el piloto: el índice de corredor en disputa no se traslada copiándolo. «Distancia al río San Juan» es del Chocó; nacionalmente el concepto es cercanía a un corredor disputado, que en el Pacífico son ríos, en Catatumbo y Arauca fronteras, y en el centro carreteras. La variable se reconstruye desde el concepto, y se vuelve a probar en cada región.

§ 3

Violencia: los otros desenlaces

Si la arquitectura sirve para reclutamiento, sirve para los demás hechos. Estos son los que tienen registro municipal y fechado.

Variable	Fuente	Cómo está
Homicidio, desaparición y secuestro	verdata · JEP–CEV–HRDAG	pública · misma estructura que reclutamiento, con capturas

Variable	Fuente	Cómo está
Quince hechos victimizantes	Observatorio de Memoria y Conflicto, CNMH	pública · servicio ArcGIS consultable, 1944–2026
Desplazamiento forzado y confinamiento	UARIV · Registro Único de Víctimas / OCHA	pública · municipal y anual
Minas antipersonal y artefactos	Oficina del Alto Comisionado para la Paz	pública · por municipio y fecha
Homicidios y delitos de alto impacto	Policía Nacional · SIEDCO	parcial · el detalle mensual municipal se pide
Violencia sexual e interpersonal	Medicina Legal · Forensis	pública · anuarios municipales

§ 4

Actores armados: el bloque que hoy no existe

Es el que su visor necesita y el más incompleto. Sin él no se puede separar qué hace cada grupo, y la disputa entre grupos es justamente lo que el piloto sugiere que importa.

Variable	Fuente	Cómo está
Presencia de grupos por municipio y año	INDEPAZ · FIP · CERAC	pública en informes · hay que estructurarla a mano
Alertas tempranas con actor y fecha	Defensoría del Pueblo · SAT	los documentos son públicos; la base no
Nivel de cumplimiento de las recomendaciones	Defensoría del Pueblo · seguimiento	en los informes de seguimiento, sin consolidar
Desmovilizaciones y reincorporación	ARN · Ministerio de Defensa	agregado nacional público; municipal se pide
Número de grupos coexistiendo	derivada de las anteriores	se calcula · es el indicador de disputa

§ 5

Economías ilegales: por qué vale la pena pelear un territorio

En el piloto, la coca resultó ser el mejor componente del índice de corredor para la violencia posterior al acuerdo. Conviene completar la familia.

Variable	Fuente	Cómo está
Coca, por municipio y año	UNODC–SIMCI	ya la tenemos · 1999–2024
Explotación de oro de aluvión	UNODC · EVOA	pública · municipal, varios cortes
Títulos mineros y minería sin título	Agencia Nacional de Minería	pública · catastro minero
Amapola y marihuana	UNODC–SIMCI	pública · menos cobertura que coca
Incautaciones y laboratorios	Policía Antinarcóticos	agregado público; municipal se pide

§ 6

Niñez y protección: el bloque propio del reclutamiento

Aquí está la variable más valiosa que no es pública, y la que más mejoraría el piloto.

Variable	Fuente	Cómo está
NNA desvinculados atendidos, por municipio y año	ICBF · programa de atención especializada	no pública · es la petición de mayor rendimiento
Procesos de restablecimiento de derechos	ICBF · PARD, por causa	no pública al nivel que sirve
Deserción escolar por municipio, grado y edad	Ministerio de Educación · SIMAT	agregados públicos; el detalle se pide
Cobertura neta y matrícula	Ministerio de Educación	pública · municipal y anual
Embarazo adolescente y nacimientos	DANE · estadísticas vitales	pública · municipal y anual
Defensorías de familia y comisarías	ICBF · municipios	no consolidada · se pide

§ 7

Estado: quién podría responder

El piloto termina diciendo que sin una entidad que responda el sistema no sirve. Estas variables miden si esa entidad existe en el territorio.

Variable	Fuente	Cómo está
Medición de Desempeño Municipal	DNP	pública · anual, todos los municipios
Desempeño fiscal, regalías y ejecución	DNP · SICODIS	pública · anual
Categoría municipal (Ley 617)	Contaduría General	pública · anual
Municipios PDET y avance de obras	Agencia de Renovación del Territorio	lista pública; el avance se pide
Distancia y tiempo a la cabecera departamental	IGAC · INVIAS	se calcula · proxy de accesibilidad del Estado

§ 8

Social, demográfico y territorial

El sustrato de vulnerabilidad. Casi todo es público y barato de incorporar.

Variable	Fuente	Cómo está
Población proyectada	DANE	ya la tenemos
Necesidades básicas insatisfechas e IPM	DANE · censo y estimaciones	pública · municipal
Pobreza monetaria municipal	DANE · estimación de áreas pequeñas	pública · cobertura parcial
Resguardos indígenas y consejos comunitarios	Agencia Nacional de Tierras	pública · polígonos
Ruralidad y áreas protegidas	DNP · Parques Nacionales	pública
Migración y población flotante	Migración Colombia	pública · municipal
Resultados electorales municipales	Registraduría	pública · histórico completo

§ 9

La estrategia de solicitudes

A quién, qué pedirle exactamente, y qué dice la ley.

Dos normas sostienen todo esto. La Ley 1712 de 2014 establece que la información en poder del Estado es pública salvo reserva expresa, y que la carga de justificar la reserva es de la entidad, no suya. La Ley 1755 de 2015 fija los plazos: diez días hábiles para una solicitud de documentos o información, quince para una petición general, treinta para una consulta.

Y trae una palanca que conviene conocer: si la entidad no responde una solicitud de información en diez días, se entiende aceptada para todos los efectos legales, y ya no puede negarse a entregar; las copias deben darse en los tres días siguientes. Si no puede cumplir el plazo, debe avisarle antes de que venza, explicando por qué y fijando uno nuevo que no puede exceder el doble del original.

Encabece siempre como solicitud de acceso a información pública invocando las dos leyes, no como petición genérica: activa el plazo de diez días y la regla del silencio.

#	A quién	Qué pedir exactamente	Por qué primero
1	Defensoría del Pueblo Sistema de Alertas Tempranas	Base de alertas 2010–2026 con: código DIVIPOLA, fecha de emisión, tipo (temprana, estructural, inminencia), actores señalados, hechos advertidos y nivel de cumplimiento registrado en el seguimiento.	Convierte concordancia en anticipación. Es el único dato que permite probar si el modelo aporta algo sobre lo que ya se advierte.
2	ICBF Dirección de Protección	NNA desvinculados de grupos armados atendidos, por municipio de ocurrencia y año, 2010–2026, agregado y sin datos individuales. Y procesos de restablecimiento de derechos por causa, mismo corte.	Es la única medición de reclutamiento que llega hasta hoy. Cierra el hueco 2018–2026.
3	UARIV Registro Único de Víctimas	Hechos victimizantes por municipio, año y presunto responsable, 1985–2026. El reporte público no desagrega por responsable.	Sin responsable no hay visor por grupo armado.
4	Ministerio de Defensa y Policía Nacional	SIEDCO mensual municipal por tipo de delito, 2010–2026. Desmovilizaciones individuales por municipio de procedencia y grupo, agregadas por año.	Da la serie reciente y la contraparte de la presencia armada.
5	Ministerio de Educación SIMAT	Deserción escolar por municipio, año, grado y edad simple, 2010–2026.	La deserción es el mejor candidato a predictor temprano de reclutamiento.
6	JEP Caso 07	Anexos estadísticos de los autos del macrocaso, en formato de datos. Y las condiciones de acceso académico al expediente anonimizado.	Formaliza la fuente del piloto y abre los otros macrocasos.

#	A quién	Qué pedir exactamente	Por qué primero
7	Agencia de Renovación del Territorio	Avance de obras y ejecución PDET por municipio y año.	Mide presencia efectiva del Estado, no solo su promesa.

Las dos primeras están resaltadas porque son las que cambian el trabajo. Mándelas esta semana; las demás pueden esperar. Y mándelas por separado, una entidad por solicitud: una petición múltiple se responde al ritmo de la dependencia más lenta.

§ 10

Modelo de solicitud

Cópielo, cambie lo que va entre corchetes y mándelo. Cabe en una página.

> Señores
> [ENTIDAD] — [DEPENDENCIA]
>
> Asunto: solicitud de acceso a información pública (Ley 1712 de 2014 y Ley 1755 de 2015)
>
> Alexander Beltrán, identificado como aparece al pie, estudiante de la Maestría en Ciencia de Datos de la Universidad Ean, respetuosamente solicito el acceso a la siguiente información pública, con fines exclusivamente académicos y de investigación:
>
> 1. [Descripción exacta del conjunto, con los campos que necesita.]
> 2. Período: [años]. Desagregación: municipio (código DIVIPOLA) y año.
> 3. Formato: CSV o Excel, con su diccionario de datos.
>
> Dejo constancia de que no solicito datos personales ni identificables, ni información desagregada por debajo del nivel municipal, ni información sometida a reserva legal. De existir reserva sobre parte de lo pedido, solicito la entrega de la parte no reservada, conforme al principio de divulgación parcial del artículo 21 de la Ley 1712 de 2014, indicando la norma concreta que ampara lo retenido.
>
> El resultado de la investigación será de acceso público y la fuente será citada expresamente.
>
> Notificaciones: [correo].
>
> Cordialmente,
> [Nombre, documento, teléfono]

LO QUE NO VAMOS A PEDIR, Y CONVIENE DECIRLO EN LA SOLICITUD

Un sistema que señala dónde hay niñas y niños reclutables es de doble uso. La línea no se traza al final: se traza al pedir. No se solicita, y se dice expresamente que no se solicita: datos personales o identificables; ubicación por debajo del municipio —veredas, corregimientos, coordenadas—; posiciones, rutas o corredores de grupos armados; ni información operativa de la fuerza pública.

Decirlo tiene además un efecto práctico: le quita a la entidad el argumento más fácil para negar la solicitud entera, y acota la reserva a lo que de verdad la tiene.

Un orden posible para los próximos dos meses. Esta semana, las dos primeras solicitudes y la descarga de los otros tres hechos de verdata, que ya son públicos. La siguiente, los bloques públicos baratos: DNP, DANE, Registraduría, ANT. Después, estructurar la presencia de grupos armados a partir de los informes de INDEPAZ y la FIP, que es trabajo manual y conviene empezarlo temprano. Y mientras llegan las respuestas, reconstruir el panel del Chocó con verdata y todos los actores, que no depende de nadie.

Fuentes de los plazos legales: Ley 1755 de 2015, artículo 14; Ley 1712 de 2014, artículos 18, 19 y 21, verificados en el texto de las normas. Las rutas de descarga de las ocho fuentes que ya usa el piloto están en FUENTES.md del repositorio; las demás fueron verificadas como existentes pero sus enlaces todavía no están recogidos en un solo documento. Lo marcado como «se pide» es nuestra estimación de que no está publicado al nivel que necesitamos, y puede equivocarse: si al pedirlo resulta ser público, mejor.